

Институт динамики систем и теории управления имени В.М. Матросова,
Сибирское отделение Российской академии наук (ИДСТУ СО РАН)



Семестровая работа

Дородных Никита Олегович

Кандидат технических наук, старший научный сотрудник
Лаборатории 4.2 и Молодёжной лаборатории по ИИ, обработке и анализу данных
ИДСТУ СО РАН


Искусственный интеллект

Искусственный Интеллект (ИИ) — наука и технология создания интеллектуальных машин, особенно интеллектуальных компьютерных программ.

Области ИИ:

- Обработка естественного языка (*Natural Language Processing*) → **Извлечение информации**
- Инженерия знаний (*Knowledge Engineering*) → **Разработка баз знаний**
- Машинное обучение (*Machine Learning*) → **Нейронные сети**
- Ителлектуальный анализ данных (*Data Mining & Knowledge Discovery*)
- Мультиагентные системы (*Multi-Agent Systems*)
- Нечеткая логика (*Fuzzy Logic*)
- Робототехника (*Robotics*)
- Когнитивное моделирование (*Cognitive Modeling*) и др.

Обработка естественного языка (Natural Language Processing – NLP)



Извлечение информации из текстов

Основное направление в *обработке естественного языка (NLP)* – это извлечение информации из текстов (**Information Extraction**).

В качестве извлекаемых из текстов данных обычно выступают:

- **Значимый объект:** имя персоналии, название компании и пр. для новостных сообщений, термин предметной области специального текста, ссылка на литературу для научно-технических документов и т. д.
- **Атрибуты объекта,** дополнительно характеризующие его, например, для компании – это юридический адрес, телефон, имя руководителя и т.п.
- **Отношение между объектами:** к примеру, отношение «быть владельцем» связывает компанию и персону-владельца, «быть частью» соединяет факультет и университет.
- **Событие/факт,** связывающее несколько объектов, например, событие «прошла встреча» включает участников встречи, а также место и время ее проведения.

Основные задачи извлечения информации из текстов

Согласно видам извлекаемой информации общая задача извлечения информации из текстов включает следующие основные подзадачи:

- **Распознавание и извлечение именованных сущностей (*named entities*):** А.П. Чехов, Нижний Тагил, ПКО «Картография» и т.п.;
- **Выделение атрибутов (*attributes*) объектов и семантических отношений (*relations*) между ними:** даты рождения персоны, отношения «работать в» и т.д.;
- **Извлечение фактов и событий (*events*), охватывающих несколько их параметров (атрибутов),** например, событие «кораблекрушение» с атрибутами дата, время, место и т.п.

Задача **извлечения (распознавания) именованных сущностей** считается самой проработанной из области извлечения информации.

Распознавание именованных сущностей (Named Entity Recognition – NER)

Распознавание именованных сущностей (Named Entity Recognition – NER) – это задача, направленная на поиск и классификацию значимых фрагментов текста по заранее определенным категориям. Эти категории могут включать: *имена людей, названия организаций, места, даты, денежные суммы* и многое другое.

Цель NER – это выделить из неструктурированного текста ключевую информацию, идентифицировав такие сущности и определив их тип.

Популярными примерами реализации **NER** являются следующие программы (*библиотеки*):

- **Stanford CoreNLP** [<https://stanfordnlp.github.io/CoreNLP/>].
- **Apache OpenNLP** [<https://opennlp.apache.org/>] и **AllenNLP** [<https://allennlp.org/>].
- **spaCy** [<https://spacy.io/>].
- Российским решением в данной области можно назвать библиотеку с открытым исходным кодом – **DeepPavlov** [<https://deeppavlov.ai/>].

Связывание именованных сущностей (Named Entity Linking – NEL)

Логическим продолжением **NER** является задача – **связывания именованных сущностей (Named Entity Linking, NEL)**, представляющая собой поиск соответствий отдельных слов (*распознанных сущностей*) по тексту с конкретными сущностями (*экземплярами*) из базы знаний, графа знаний или онтологии (например, **DBpedia**, **Wikidata**, **YAGO**). Результатом данного процесса является текст с аннотациями (*референтными сущностями*), что позволяет:


- Осуществлять более эффективный поиск (*Information Retrieval*).
- Применять эти размеченные данные в вопросно-ответных (*Question Answering*) и рекомендательных системах.
- Осуществлять автоматическое заполнение и обогащение существующих баз знаний новыми извлеченными фактами (*Knowledge Base Population*).
- Проводить интеллектуальный анализ содержания (*Content Analysis*) и т.д.

Широко распространенными открытыми средствами для решения задачи **NEL** являются: **AIDA**, **DBpedia Spotlight**, **Dexter**, **Babelfy**, **DoSeR**, **Yahoo FEL**.

Графы знаний

Одним из видов баз знаний является – **граф знаний**.

Граф знаний (knowledge graph) – это граф данных, предназначенный для накопления и передачи знаний о реальном мире, узлы которого представляют интересующие объекты, а ребра представляют отношения между этими объектами (Hogan, 2021).



(Hogan, 2021) [Hogan et al., Knowledge Graphs. ACM Computing Surveys, 54\(4\), 1–37 \(2021\).](#)

Таблицы – Источник больших данных



Часть дневника Мерера
(около 2600 г. до н. э.)

(Peeters, 2024) [Peeters R., et al. The Web Data Commons Schema.org Table Corpora. Proc. the ACM Web Conference, 1079-1082 \(2024\).](#)
(Fedorov, 2023) [Fedorov P.E. et al. RWT: A Pub. Corpus of Web Tables for Rus. Lang. Based on Wiki.. Lob. Jour. of Math., 44, 111-122 \(2023\).](#)
(1) <https://askwonder.com/research/number-google-sheets-users-worldwide-eoskdoxav>

1

Примерно до **40%** всех таблиц расположенных в **Вебе**, обладают реляционной природой и содержат потенциально полезные факты (**Peeters, 2024**).

2

Русскоязычная версия Википедии 2021 года содержит ~ **1.4 млн.** таблиц (**Fedorov, 2023**).

3

Таблицы в формате **Google Sheets** используют около **2 млрд.** пользователей ежемесячно (**1**).

4

Microsoft Excel имеет от **750 млн.** до **1,2 млрд.** ежемесячных пользователей по всему миру (**1**).

Задание для семестровой работы (1)

1. Решение задачи **NER** для *табличных данных*, включая:

- программную реализацию выполнения процедуры **NER** на основе *стандартных, специализированных NLP-библиотек*;
- программную реализацию на основе *больших языковых моделей* с использованием *промпtingа* (как **zero-shot**, так и **few-shot** настройки).

2. Решение задачи **NEL** для *табличных данных* на основе использования графов знаний общего назначения (**DBpedia** или **Wikidata**). Программная реализация может использовать как *стандартные библиотеки* для решения **NEL**-задачи (например, **DBpedia Spotlight** или **DBpedia Lookup**), так и *большие языковые модели*.

Связывание сущностей для ячеек таблиц

Поиск **сущностей-кандидатов** в графе знаний для каждого значения ячейки столбца и **снятие неоднозначности** (например, использовать *SPARQL*-запрос и метрику расстояния Левенштейна или использовать специализированное средство поиска сущностей *DBpedia Lookup*).

Сущности-кандидаты для “Mont Blanc”
http://dbpedia.org/resource/Mont_Blan
http://dbpedia.org/resource/SS_Mont-Blanc
http://dbpedia.org/resource/TV8_Mont-Blanc
http://dbpedia.org/resource/Mont_Tout_Blan
http://dbpedia.org/resource/Mont_Blan_(Moon)
http://dbpedia.org/resource/Mont_Blan_(film)
http://dbpedia.org/resource/Mont_Blan_massif
http://dbpedia.org/resource/Refuge_Mont-Blanc
http://dbpedia.org/resource/Mont_Blan_Tunnel
http://dbpedia.org/resource/Mont_Blan_Trophy

Name	Coordinates	Height	Range
Mont Blanc	45°49'57"N 06°51'52"E	4808	Mont Blanc massif
Lyskamm	45°55'20"N 07°50'08"E	4527	Pennine Alps
Monte Cervino	45°58'35"N 07°39'31"E	4478	Pennine Alps

Сущности-кандидаты для “Lyskamm”

http://dbpedia.org/resource/Lyskamm
http://dbpedia.org/resource/Western_Lyskamm

Задание для семестровой работы (2)

- 3.** Создание небольшого тестового набора **табличных данных** путем ручной разметки (*аннотирования*) ячеек таблиц определенными **NER**-категориями (*метками*).

- 4.** Разработка скриптов **получения экспериментальной оценки производительности решения задачи NER** (*для сравнения обоих вариантов*) с использованием созданного тестового набора табличных данных и стандартных метрик оценки качества таких как: **точность (precision), полнота (recall) и F-мера (F1)**.

Основные требования к заданию (1)

1. В качестве исходных наборов табличных данных предлагается использовать:

- русскоязычный набор таблиц – **RF-200 (ru-facts-200)** [<https://github.com/YRL-AIDA/ru-facts-200>];
- англоязычные наборы таблиц такие как: **T2Dv2** [<https://webdatacommons.org/webtables/goldstandardV2.html>] и **Tough Tables (2T)** [<https://vcutrona.github.io/publication/2t/>].

2. Создание размеченного набора табличных данных для тестирования задачи **NER** должно осуществляться на основе выборки некоторых таблиц из приведенных выше наборов. Предполагается не менее **10** проверочных таблиц (*точное количество уточняется с преподавателем*).

Основные требования к заданию (2)

3. Программная реализация должна быть выполнена с использованием языка **Python** и библиотек **PyTorch**, **Transformers** и **LangChain** (*для работы с языковыми моделями*).
4. Разработанная программа должна обеспечивать **консольное взаимодействие** с пользователем и сохранение всех результатов обработки в виде отдельных **json**-файлов (*дополнительно к отображению результатов на консоль*).
5. Разработанная программа должна включать документацию (*подробное описание программы + руководство пользователя*).

Институт динамики систем и теории управления имени В.М. Матросова,
Сибирское отделение Российской академии наук (ИДСТУ СО РАН)

Семестровая работа

Спасибо за внимание!

Дородных Никита Олегович

Телефон: +7 950 104-99-45

Эл. почта: DorodnyxNikita@gmail.com